Карточка методологии исследования (Methodology Passport Card)

1. Информация о проекте

- **Название работы:** Machine Learning Approaches for Phishing Website Detection: A Comparative Performance Analysis
- **Авторы (пара):** Alinur Bedelkhan, Agadilkhan Nurdaulet
- **GitHub-репозиторий:** https://github.com/Aliko404/phishing-ml-benchmark

2. Тип исследования

Количественное (экспериментальное). Все выводы строятся на числовых метриках (accuracy, precision, recall, F1, время инференса), измеряемых в контролируемом эксперименте на одном наборе данных с фиксированным разбиением, и проверяются статистическими тестами. Качественные методы (интервью, контент-анализ) не используются: цель — измеримое сравнение алгоритмов и эффекта отбора признаков, а не интерпретация мнений.

3. Формулировка гипотез

Гипотезы Task 1 уточнены: H1 («высокая точность») операционализирована порогом, H2 и H3 сделаны статистически проверяемыми.

Гипотеза A (RQ1) — точность обнаружения

- **H_0(A):** истинная accuracy лучшего классификатора на тестовой выборке не превышает 95 % (accuracy ≤ 0,95).
- **H_1(A):** истинная accuracy лучшего классификатора превышает 95 % (accuracy > 0,95).

Гипотеза B (RQ2) — сравнение алгоритмов

- **H_0(B):** медианные значения F1-score и времени инференса для всех сравниваемых алгоритмов равны (различий нет).
- **H_1(B):** существует хотя бы одна пара алгоритмов, различающихся по F1-score или по времени инференса (уровень значимости α = 0,05; тест Фридмана + post-hoc Вилкоксона с поправкой Холма по повторным фолдам).

Гипотеза C (RQ3) — отбор признаков

- **H_0(C):** отбор признаков не изменяет F1-score и время инференса относительно модели на полном наборе признаков (ΔF1 = 0, Δtime = 0).
- **H_1(C):** отбор признаков изменяет F1-score и/или снижает время инференса относительно полного набора признаков (ΔF1 ≠ 0 или Δtime < 0), α = 0,05.

4. Матрица переменных

Тип	Переменная	Значения / единицы
Независимая	Алгоритм ML	Logistic Regression, Decision Tree, Random Forest, SVM, KNN, Gradient Boosting, AdaBoost
Независимая	Метод отбора признаков	none, mutual information (top-k), RF importance (top-k), PCA
Зависимая	Accuracy	доля, 0–1
Зависимая	Precision	доля, 0–1 (класс «phishing»)
Зависимая	Recall	доля, 0–1 (класс «phishing»)
Зависимая	F1-score	0–1 (класс «phishing»)
Зависимая	Время инференса	мс на один объект (медиана по повторам)
Зависимая	Время обучения / пиковая RAM	с / МБ
Контролируемая	Датасет	один и тот же набор phishing/legitimate URL с признаками (фиксируется на Неделе 7)
Контролируемая	Набор признаков (до отбора)	одинаковый для всех алгоритмов
Контролируемая	Разбиение train/test	стратифицированное, test_size = 0,3, seed = 42

Контролируемая	Аппаратное обеспечение и ОС	один и тот же компьютер; запуск в Docker (python:3.13-slim), OMP_NUM_THREADS = 1
Контролируемая	Версии библиотек	numpy 2.5.3, pandas 3.0.5, scikit-learn 1.9.1, PyYAML 6.0.3
Контролируемая	Предобработка	StandardScaler, обучается только на train
Контролируемая	Гиперпараметры	фиксированы в `configs/config.yaml` (одинаковый бюджет настройки)

5. Метрики и Baseline

- **Первичная метрика (Primary):** F1-score по классу «phishing» на тестовой выборке (для гипотезы A дополнительно — accuracy с 95 % доверительным интервалом). F1 выбран, так как баланс precision и recall важнее accuracy при возможном дисбалансе классов.
- **Вторичные метрики:** accuracy, precision, recall, время инференса (мс/объект), время обучения, пиковая RAM.
- **Пороговые метрики (Guardrail):**
  - recall по классу «phishing» ≥ 0,90 (пропуск фишинга недопустим);
  - время инференса ≤ 5 мс на объект;
  - пиковая RAM при обучении ≤ 1024 МБ;
  - отсутствие неудачных запусков (status ≠ ok). Модель, не прошедшая guardrail, не может считаться «лучшей», даже при высоком F1.
- **Baseline (контрольная точка):** Logistic Regression на полном наборе признаков без отбора — простой, интерпретируемый и стандартный линейный классификатор; результат любой другой конфигурации сравнивается с ним через `f1_delta_vs_baseline`. Для гипотезы C базой служит та же модель того же алгоритма с `feature_selection = none`.

6. Ограничения и план валидации

- Тестовый запуск использует синтетический сэмпл из 10 строк, только для проверки работы пайплайна.
- На Неделе 7 hold-out заменяется повторной стратифицированной k-fold валидацией для статистических тестов.
- Результаты зависят от выбранного датасета и могут не переноситься на новые фишинговые сайты (ограничение внешней валидности).